


Insurance Cost Prediction – Machine Learning Project (Dataiku + Python)



Obiettivo del Progetto

Il progetto ha l'obiettivo di prevedere il costo sanitario annuale dei pazienti utilizzando tecniche di Machine Learning.

L'obiettivo business è supportare le compagnie assicurative nella:

- definizione dei premi assicurativi
- gestione del rischio
- identificazione dei clienti ad alto costo sanitario


Panoramica del Progetto

Questo progetto simula un vero caso aziendale nel settore assicurativo utilizzando dati reali Kaggle.

Variabile target:

- **charges (costo sanitario annuale)**

Workflow di Machine Learning (Dataiku DSS)



Il progetto è stato sviluppato utilizzando la piattaforma Dataiku e segue queste fasi:

1. Importazione dataset
2. Data Cleaning
3. Feature Engineering
4. Encoding variabili categoriche
5. Split training/test
6. Training modelli ML
7. Valutazione performance
8. Deploy modello
9. Predizione su nuovi dati


Feature Engineering

Sono state create nuove variabili per migliorare il modello:

- `age_group` (fasce di età)
- `bmi_class` (classificazione BMI)
- `has_children` (flag presenza figli)

Modelli Utilizzati

Sono stati confrontati due modelli:



1. Linear Regression

- modello interpretabile
- buona baseline

2. Random Forest Regression

- migliore performance
- cattura relazioni non lineari

Il modello migliore è risultato: **Random Forest**

Valutazione del Modello

Metriche utilizzate:

- R^2 Score
- Analisi errore predittivo

Feature Importance

Le variabili più influenti sul costo sanitario sono:

- smoker (fattore principale)
- bmi
- age

Test su Nuovi Dati

Il modello è stato testato su nuovi clienti simulati utilizzando una pipeline di scoring.

Output:

- predizione del costo sanitario per ogni cliente

Insight di Business

- I fumatori hanno costi significativamente più alti
- L'età aumenta il costo sanitario
- BMI elevato è correlato a costi maggiori

Struttura del Progetto

- Dataiku Flow (pipeline completa)
- Dataset originale Kaggle
- Dataset preprocessato
- Modello ML salvato
- Dataset predizioni finali

Tecnologie Utilizzate

- Dataiku DSS
- Python
- Pandas
- Scikit-learn
- Machine Learning (Regression Models)

Sviluppi Futuri

- Aggiunta di modelli avanzati (XGBoost, LightGBM)
- Deployment API del modello
- Dashboard interattiva (Power BI / Streamlit)
- Automazione pipeline ML

Conclusione

Questo progetto rappresenta un workflow completo di Data Science:
dalla raccolta dati fino alla predizione e interpretazione business-ready.

Autore

Cecile Mbazona

Studentessa Data Analyst

Interessi: Machine Learning, Data Science, Modellazione dei sistemi informatici